

CN2 – Generovanie rozhodovacích zoznamov

Praktické zadanie zo Strojového učenia

Martin Šulák

6. mája 2026

Obsah

1	Úvod	2
2	Teoretický základ	2
2.1	Rozhodovacie zoznamy	2
2.2	Algoritmus CN2	3
2.3	Selektor, komplex a pravidlo	3
2.4	Hodnotenie kvality pravidla	4
2.5	Numerické charakteristiky pravidla	4
3	Návrh riešenia	4
3.1	Architektúra projektu	4
3.2	Obmedzenia implementácie	5
3.3	Vstupy a výstupy aplikácie	5
3.4	Používané parametre	6
4	Implementácia	6
4.1	Triedy <code>Selector</code> , <code>Complex</code> a <code>Rule</code>	6
4.2	Tréning modelu	6
4.3	Vyhľadanie najlepšieho komplexu	7
4.4	Výpočet metrík	7
4.5	Ukážka spustenia	7
5	Používané datasety	7
5.1	Dataset <code>play_tennis.csv</code>	7
5.2	Dataset <code>student_performance_clean.csv</code>	8
5.3	Dataset <code>student_performance_noisy.csv</code>	8
6	Experimenty	8
6.1	Nastavenie hlavného behu	8
6.2	Sledované metriky	9
6.3	Poznámka k rozsahu experimentov	9

7	Výsledky	9
7.1	Hlavný beh aplikácie	9
7.2	Confusion matrix hlavného behu	10
7.3	Naučené pravidlá hlavného behu	10
7.4	Charakteristiky pravidiel	11
7.5	Zhrnutie výsledkov	12
8	Záver	12

1 Úvod

Cieľom tejto práce je implementovať algoritmus CN2 pre generovanie rozhodovacích zoznamov a overiť jeho správanie na kategorizovaných dátach. Výsledkom riešenia je samostatná Python aplikácia, ktorá načíta dátovú množinu zo súboru CSV, rozdelí ju na tréningovú a testovaciu časť, natrénuje model CN2, vypíše naučené pravidlá a vyhodnotí klasifikáciu.

Téma patrí do oblasti indukcie klasifikačných pravidiel. Rozhodovací zoznam je vhodný najmä vtedy, keď je okrem samotnej presnosti dôležitá aj interpretovateľnosť modelu. Výsledný model má tvar usporiadaného zoznamu pravidiel typu IF - THEN. Pri klasifikácii sa pravidlá testujú v pevnom poradí a použije sa prvé pravidlo, ktorého podmienka je splnená.

Práca je orientovaná na multitriednu klasifikáciu študentského výkonu. Hlavným datasetom je vlastná dátová množina `student_performance_clean.csv`, ktorá obsahuje tri triedy cieľového atribútu `vykon`: `nizky`, `stredny` a `vysoky`. Okrem čistej verzie datasetu bola pripravená aj zašumená verzia `student_performance_noisy.csv`. Malý dataset `play_tennis.csv` slúži ako ilustračná pomôcka pri vysvetlení princípu CN2.

V tejto opravenej verzii reportu sú opisované len tie časti riešenia a tie výstupy, ktoré sa zhodujú s aktuálnym obsahom verejného repozitára. Hlavná pozornosť je preto venovaná jednému reprodukovateľnému behu aplikácie nad `clean` datasetom, ku ktorému sú v repozitári uložené textové, tabuľkové aj grafické výstupy.

Hlavné ciele práce sú nasledujúce:

- implementovať vlastný klasifikátor CN2 pre kategorické atribúty,
- vytvoriť funkčnú aplikáciu použiteľnú z príkazového riadku,
- overiť model na hlavnom datasete a vyhodnotiť jeho správanie,
- analyzovať naučené pravidlá, ich cenu, konzistenciu a úplnosť,
- pripraviť výstupy vhodné na interpretáciu a obhajobu.

Práca je rozdelená na teoretickú, návrhovú, implementačnú a experimentálnu časť. V závere sú zhrnuté dosiahnuté výsledky a naznačené možné rozšírenia riešenia.

2 Teoretický základ

2.1 Rozhodovacie zoznamy

Rozhodovací zoznam je usporiadaný systém pravidiel. Na rozdiel od neusporiadaného systému pravidiel tu poradie pravidiel priamo ovplyvňuje výsledok klasifikácie. Pri klasifikovaní nového príkladu sa pravidlá vyhodnocujú zhora nadol a použije sa prvé pravidlo, ktorého podmienka je splnená. Ak sa nespustí žiadne explicitné pravidlo, použije sa defaultné pravidlo.

Všeobecný tvar rozhodovacieho zoznamu možno zapísať nasledovne:

```
IF  $D_1$  THEN  $C_1$ 
ELSE IF  $D_2$  THEN  $C_2$ 
ELSE IF  $D_3$  THEN  $C_3$ 
    ⋮
ELSE  $C_{\text{default}}$ 
```

Výhodou takéhoto modelu je dobrá interpretovateľnosť. Používateľ vie presne určiť, ktoré pravidlo bolo použité a prečo bol príklad zaradený do danej triedy.

2.2 Algoritmus CN2

Algoritmus CN2 patrí medzi algoritmy indukujúce klasifikačné pravidlá. Ide o neinkrementálny algoritmus, ktorý vytvára rozhodovací zoznam po jednom pravidle. V každej iterácii hľadá najlepší komplex, z ktorého vytvorí nové pravidlo. Následne odstráni všetky príklady pokryté týmto pravidlom a pokračuje na zvyšných príkladoch.

CN2 používa stratégiu *general-to-specific*. Hľadanie sa začína od najvšeobecnejšieho komplexu TRUE a postupne sa vytvárajú jeho špecializácie pridávaním nových selektorov. Priestor kandidátov môže rásť veľmi rýchlo, preto CN2 používa *beam search*, teda obmedzenie počtu najlepších kandidátov, ktoré sa uchováva v množine STAR.

Zjednodušený princíp učenia možno zhrnúť takto:

1. Vygeneruje sa množina všetkých selektorov vo forme **atribút = hodnota**.
2. Vyhľadá sa najlepší komplex pomocou beam search.
3. Komplexu sa priradí majoritná trieda pokrytých príkladov.
4. Vytvorené pravidlo sa pridá do rozhodovacieho zoznamu.
5. Pokryté príklady sa odstránia z aktuálnej trénovacej množiny.
6. Postup sa opakuje, kým je možné vytvoriť ďalšie pravidlo.

2.3 Selektor, komplex a pravidlo

Selektor je najmenšia podmienka, napríklad:

dochadzka = vysoka

Komplex je konjunkcia viacerých selektorov, napríklad:

dochadzka = vysoka AND domace_ulohy = pravidelne

Pravidlo vznikne priradením triedy ku komplexu, napríklad:

IF dochadzka = vysoka AND domace_ulohy = pravidelne THEN vykon = vysoky

2.4 Hodnotenie kvality pravidla

V tejto implementácii je kvalita kandidátskeho komplexu vyhodnocovaná pomocou Laplaceho odhadu. Ak komplex pokrýva n príkladov a z nich n_c patrí do danej triedy, potom Laplaceho skóre je:

$$Q_{\text{Laplace}} = \frac{n_c + 1}{n + k},$$

kde k je počet tried.

Tento spôsob hodnotenia zvýhodňuje komplexy, ktoré sú zároveň presné aj dostatočne všeobecné. Nepreferuje príliš úzke pravidlá pokrývajúce len niekoľko príkladov.

2.5 Numerické charakteristiky pravidla

Pri interpretácii pravidiel sú použité tieto charakteristiky:

- **cena pravidla** – počet podmienok v komplexe,
- **konzistencia** – podiel správne pokrytých príkladov z celkového počtu pokrytých príkladov,
- **úplnosť** – podiel správne pokrytých príkladov danej triedy z celkového počtu príkladov tejto triedy.

Ak pravidlo pokrýva K príkladov a správne z nich pokrýva K_r , potom platí:

$$\text{konzistencia} = \frac{K_r}{K}$$

a ak je v trénovacej množine celkovo N_r príkladov danej triedy, potom:

$$\text{úplnosť} = \frac{K_r}{N_r}.$$

Tieto charakteristiky umožňujú posúdiť nielen presnosť pravidla, ale aj jeho praktickú užitočnosť.

3 Návrh riešenia

Riešenie bolo navrhnuté ako samostatná konzolová Python aplikácia. Dôvodom bolo zachovanie jednoduchého spúšťania, prehľadná modularita a možnosť ľahkého testovania rôznych datasetov a parametrov.

3.1 Architektúra projektu

Aktuálny verejný repozitár obsahuje tieto hlavné časti projektu:

- `main.py` – vstupný bod aplikácie,
- `cn2.py` – implementácia jadra algoritmu CN2,
- `config.py` – centrálna nastavenia ciest a parametrov,
- `rule.py` – reprezentácia selektora, komplexu a pravidla,

- `data_utils.py` – načítanie, validácia a delenie datasetu,
- `metrics.py` – výpočet metrík a sumarizácia pravidiel,
- priečinok `datasets/` – vstupné dátové množiny,
- priečinok `outputs/` – exportované výsledky hlavného behu,
- priečinok `reports/` – finálny report vo formáte PDF.

Takéto rozdelenie zjednodušuje orientáciu v projekte a zároveň umožňuje nezávisle meniť jednotlivé časti bez zásahu do zvyšku aplikácie.

3.2 Obmedzenia implementácie

Implementácia bola navrhnutá vedome pre kategorické atribúty. Každá hodnota atribútu je preto interpretovaná ako textová kategória. Táto voľba bola zvolená z troch dôvodov:

1. selektory typu `atribút = hodnota` sa implementujú priamo a jednoducho,
2. výsledné pravidlá sú ľahko čitateľné,
3. nie je potrebné riešiť discretizáciu spojitých atribútov.

Spracovanie spojitých atribútov je možné doplniť neskôr po pridanej discretizácii alebo rozšírení operátora selektora.

3.3 Vstupy a výstupy aplikácie

Vstupom aplikácie je CSV súbor, v ktorom sa posledný stĺpec chápe ako cieľový atribút. Aplikácia očakáva, že:

- dataset neobsahuje chýbajúce hodnoty,
- všetky atribúty sú kategorické,
- názov cieľového atribútu je známy pri spustení,
- cieľový atribút sa nachádza v poslednom stĺpci.

Hlavné výstupy uložené po spustení aplikácie sú:

- `learned_rules.txt` – textová podoba rozhodovacieho zoznamu,
- `metrics.json` – základné metriky hlavného behu,
- `confusion_matrix.csv` – tabuľka zámien tried,
- `rule_summary.csv` – detailné charakteristiky pravidiel.

Okrem toho repozitár obsahuje aj doplnkové grafické súbory v priečinku `outputs/plots`, ktoré boli použité v tejto správe pri vizualizácii confusion matrix, ceny pravidiel a pokrytia pravidiel.

3.4 Použité parametre

V hlavnom analyzovanom behu boli najdôležitejšie tieto parametre:

- `beam_width` – počet kandidátov uchovávaných v množine **STAR**,
- `min_coverage` – minimálny počet pokrytých príkladov, aby bol komplex akceptovaný,
- `max_rule_length` – maximálny počet podmienok v jednom pravidle,
- `test_size` – veľkosť testovacej množiny pri rozdelení dát.

V hlavnom behu, ktorého výsledky sú rozoberané podrobnejšie, boli použité hodnoty `beam_width = 5`, `min_coverage = 2`, `max_rule_length = 4` a `test_size = 0.2`.

4 Implementácia

4.1 Triedy Selector, Complex a Rule

Súbor `rule.py` obsahuje tri základné dátové štruktúry:

- **Selector** reprezentuje jednu podmienku `atribút = hodnota`,
- **Complex** reprezentuje konjunkciu selektorov,
- **Rule** reprezentuje klasifikačné pravidlo vo forme `IF komplex THEN trieda`.

Každá z týchto štruktúr obsahuje metódu `matches()`, ktorá určuje, či daný príklad spĺňa príslušnú podmienku.

4.2 Tréning modelu

Hlavné správanie modelu je implementované v triede `CN2Classifier`. Pri volaní metódy `fit()` prebieha učenie nasledovne:

1. z trénovacej množiny sa vytvorí zoznam všetkých selektorov,
2. inicializuje sa prázdny rozhodovací zoznam,
3. na aktuálnej množine sa vyhľadá najlepší komplex,
4. komplexu sa priradí majoritná trieda pokrytých príkladov,
5. vytvorené pravidlo sa uloží do zoznamu pravidiel,
6. pokryté príklady sa odstránia,
7. postup sa opakuje až do zastavenia.

Ak po ukončení iterácií ešte ostanú nepokryté príklady, určí sa z nich defaultná trieda.

4.3 Vyhľadanie najlepšieho komplexu

Kľúčovou časťou implementácie je metóda `_find_best_complex()`. Táto metóda realizuje beam search nad množinou **STAR**. Najprv sa do **STAR** vloží prázdny komplex. Následne sa opakovane vykonáva:

1. špecializácia každého komplexu zo **STAR** o jeden nový selektor,
2. vyradenie kandidátov, ktorí nespĺňajú minimálne pokrytie,
3. výpočet Laplaceho skóre pre zostávajúcich kandidátov,
4. zotriedenie kandidátov podľa kvality,
5. ponechanie najlepších kandidátov podľa `beam_width`.

Pri rovnosti skóre sa používa pomocné poradie: najprv sa preferuje väčšie pokrytie majoritnej triedy, potom väčšie celkové pokrytie a napokon nižšia cena pravidla.

4.4 Výpočet metrík

Po natrénovaní modelu sa na testovacej množine vypočíta:

- **accuracy**,
- **confusion matrix**,
- **počet pravidiel**,
- **priemerná cena pravidla**,
- tabuľka s detailmi o jednotlivých pravidlách.

Súbor `rule_summary.csv` obsahuje pre každé pravidlo jeho textovú podobu, Laplaceho skóre, pokrytie, cenu, konzistenciu, úplnosť a veľkosť trénovacej množiny, na ktorej sa dané pravidlo naučilo.

4.5 Ukážka spustenia

Aplikácia sa spúšťa z príkazového riadku. Základný príkaz pre hlavný dataset je:

```
python main.py --dataset datasets/student_performance_clean.csv --target vykon
```

Po spustení sa do konzoly vypíšu pravidlá, základné metriky a confusion matrix. Zároveň sa do výstupných súborov uložia textové a tabuľkové výsledky. Grafické obrázky použité v tejto správe sú uložené v repozitári ako doplnkové súbory v priečinku `outputs/plots`.

5 Použité datasety

5.1 Dataset `play_tennis.csv`

Dataset `play_tennis.csv` je klasická malá ukážková množina obsahujúca 14 príkladov. Používa sa iba na didaktické vysvetlenie princípu CN2. Obsahuje atribúty `outlook`, `temperature`, `humidity`, `wind` a cieľový atribút `play`. Výhodou datasetu je malý rozsah a intuitívna interpretácia pravidiel.

5.2 Dataset `student_performance_clean.csv`

Hlavný dataset obsahuje 90 príkladov a bol vytvorený špeciálne pre túto prácu. Každý príklad reprezentuje fiktívneho študenta a jeho správanie z pohľadu viacerých faktorov ovplyvňujúcich výkon. Použité vstupné atribúty sú:

- `dochadzka`,
- `domace_ulohy`,
- `testy`,
- `aktivita`,
- `spanok`,
- `priprava_pred_skusou`,
- `pouzivanie_mobilu`,
- `dochvilnost`.

Cieľovým atribútom je `vykon` s triedami `nizky`, `stredny` a `vysoky`. Dataset je vyvážený, pričom každá trieda obsahuje 30 príkladov.

Pri tvorbe dát sa sledovala logická konzistentnosť. Napríklad kombinácie vysokej dochádzky, pravidelného plnenia úloh a systematickej prípravy boli častejšie spojené s triedou `vysoky`, zatiaľ čo kombinácie nízkej dochádzky, chýbajúcej prípravy a slabých výsledkov testov boli častejšie spojené s triedou `nizky`. Zároveň však boli do dát vložené aj hraničné prípady, aby model nebol triviálny.

5.3 Dataset `student_performance_noisy.csv`

Zašumená verzia vznikla úpravou čistej množiny. Pri časti príkladov bola zmenená jedna atribútová hodnota alebo cieľová trieda. Cieľom tejto úpravy bolo simulovať menej presné dáta a pripraviť podmienky na rozšírené testovanie robustnosti modelu.

V aktuálnej verzii repozitára sú detailne zdokumentované a uložené výstupy hlavne pre `clean` dataset. `Noisy` dataset ostáva súčasťou projektu ako pripravená doplnková množina pre ďalšie experimentovanie.

6 Experimenty

6.1 Nastavenie hlavného behu

Report je v tejto verzii zosúladený s aktuálnym obsahom repozitára, preto je ako hlavný analyzovaný beh použitý ten, ku ktorému sú v priečinku `outputs/` priamo uložené exportované výsledky.

Ide o beh nad datasetom `student_performance_clean.csv` s parametrami:

- `beam_width = 5`,
- `min_coverage = 2`,
- `max_rule_length = 4`,

- `test_size = 0.2`,
- `random_state = 42`.

Rozdelenie na tréningovú a testovaciu časť prebieha v implementácii po triedach, takže sa zachováva približne rovnaké zastúpenie tried v oboch častiach dát.

6.2 Sledované metriky

Pri hlavnom behu boli zaznamenané tieto ukazovatele:

- presnosť klasifikácie na testovacej množine,
- počet naučených pravidiel,
- priemerná cena pravidla,
- defaultná trieda,
- confusion matrix,
- detailné charakteristiky jednotlivých pravidiel.

Takýto súbor metrík umožňuje posúdiť nielen samotnú úspešnosť klasifikácie, ale aj komplexnosť a interpretovateľnosť modelu.

6.3 Poznámka k rozsahu experimentov

V repozitári sa nachádza aj dataset `student_performance_noisy.csv`, ktorý je pripravený na ďalšie porovnávacie testy. Keďže však aktuálne uložené výsledky zodpovedajú jednému hlavnému behu na clean datasete, táto správa sa sústreďuje predovšetkým na tento reprodukovateľný a priamo doložený výstup.

7 Výsledky

7.1 Hlavný beh aplikácie

Pri hlavnom behu aplikácie nad datasetom `student_performance_clean.csv` s parametrami `beam_width = 5`, `min_coverage = 2` a `max_rule_length = 4` boli dosiahnuté tieto výsledky:

- veľkosť tréningovej množiny: 72 príkladov,
- veľkosť testovacej množiny: 18 príkladov,
- počet naučených pravidiel: 13,
- priemerná cena pravidla: 1.8462,
- defaultná trieda: vysoký,
- accuracy: 0.9444.

Model teda klasifikoval správne 17 z 18 testovacích príkladov. Z pohľadu interpretovateľnosti je dôležité, že priemerná cena pravidla ostala nízka, takže väčšina pravidiel je krátka a dobre čitateľná.


7.2 Confusion matrix hlavného behu

Tabuľka 1 zobrazuje confusion matrix pre hlavný beh na clean datasete.

Tabuľka 1: Confusion matrix pre dataset `student_performance_clean.csv`.

Skutočná trieda	nizky	stredny	vysoky
nizky	6	0	0
stredny	0	6	0
vysoky	0	1	5

Z tabuľky vyplýva, že triedy `nizky` a `stredny` boli rozpoznané bez chyby. Jediná chyba nastala pri triede `vysoky`, kde bol jeden príklad klasifikovaný ako `stredny`. Ide teda o miernu chybu medzi susednými triedami, nie o extrémne nesprávnu klasifikáciu.



Obr. 1: Grafické zobrazenie confusion matrix pre clean dataset.

7.3 Naučené pravidlá hlavného behu

Tabuľka 2 uvádza celý rozhodovací zoznam naučený v hlavnom behu. Poslednou položkou zoznamu je defaultné pravidlo s triedou `vysoky`.

Tabuľka 2: Naučené pravidlá pre hlavný beh na clean datasete.

ID	Pravidlo	Cena
1	IF dochadzka = vysoka AND dochvilnost = dobra AND domace_ulohy = pravidelne THEN vysoky	3
2	IF dochadzka = nizka AND priprava_pred_skusou = ziadna THEN nizky	2
3	IF aktivita = stredna AND testy = priemerne THEN stredny	2
4	IF dochvilnost = zla AND domace_ulohy = zriedka THEN nizky	2
5	IF pouzivanie_mobilu = nizke AND priprava_pred_skusou = systematicka THEN vysoky	2
6	IF aktivita = vysoka AND testy = priemerne THEN stredny	2
7	IF domace_ulohy = obcas AND pouzivanie_mobilu = stredne THEN stredny	2
8	IF aktivita = vysoka THEN vysoky	1
9	IF spanok = nedostatocny AND testy = slabe THEN nizky	2
10	IF domace_ulohy = pravidelne AND pouzivanie_mobilu = vysoke THEN stredny	2
11	IF dochadzka = stredna AND dochvilnost = priemerna THEN stredny	2
12	IF testy = slabe THEN nizky	1
13	IF dochadzka = nizka THEN nizky	1
D	Default: vysoky	0

Tieto pravidlá pôsobia logicky aj z doménového hľadiska. Medzi najsilnejšie pozitívne znaky vysokej výkonnosti patria najmä vysoká dochádzka, dobrá dochvilnosť, pravidelné plnenie úloh a systematická príprava. Naopak, nízky výkon sa spája s nízkou dochádzkou, chýbajúcou prípravou, zlou dochvilnosťou alebo slabými výsledkami testov.


7.4 Charakteristiky pravidiel

Z detailnej tabuľky `rule_summary.csv` vyplýva, že prvé pravidlá mali konzistenciu 1.0 a pokrývali relatívne veľké časti trénovacej množiny. To je očakávané, pretože CN2 sa snaží v skorých iteráciách nájsť čo najkvalitnejšie a najvšeobecnejšie pravidlá. S pribúdajúcim poradím pravidla spravidla klesá pokrytie a pravidlá sa stávajú špecifickejšími.


Najsilnejšie prvé pravidlo:

IF dochadzka = vysoka AND dochvilnost = dobra AND domace_ulohy =
pravidelne THEN vysoky

pokrývalo 13 trénovacích príkladov, všetky správne, a jeho Laplaceho skóre bolo 0.875. Posledné pravidlá už pokrývali len malé zvyšky trénovacej množiny a slúžili najmä na dočistenie rozhodovacieho zoznamu.



Obr. 2: Cena jednotlivých pravidiel na clean datasete.



Obr. 3: Pokrytie jednotlivých pravidiel na clean datasete.

7.5 Zhrnutie výsledkov

Z uložených výsledkov vyplýva, že implementovaný CN2 funguje na clean kategorizovaných dátach veľmi dobre. Okrem vysokej presnosti si zachováva aj dobrú interpretovateľnosť, pretože výsledný model tvoria krátke a zmysluplné pravidlá. V aktuálnej verzii repozitára je najlepšie zdokumentovaný práve tento hlavný beh, ktorý poskytuje dostatočný základ pre obhajobu aj ďalšie rozširovanie projektu.

8 Záver

Výsledkom práce je funkčná implementácia algoritmu CN2 pre generovanie rozhodovacích zoznamov nad kategorizovanými dátami. Vytvorená aplikácia dokáže načítať dataset zo súboru CSV, skontrolovať jeho korektnosť, rozdeliť ho na tréningovú a testovaciu časť, natrénovať model, klasifikovať nové príklady a vypočítať základné metriky.

Na hlavnom datasete `student_performance_clean.csv` dosiahol model pri parametroch `beam_width = 5`, `min_coverage = 2` a `max_rule_length = 4` presnosť 0.9444. Rozhodovací zoznam pozostával z 13 pravidiel a jedného defaultného pravidla. Priemerná cena pravidla bola 1.8462, čo potvrdzuje, že výsledný model je nielen presný, ale aj dobre interpretovateľný.

Za hlavný prínos práce považujem najmä:

- vlastnú implementáciu CN2 bez použitia hotového klasifikátora,
- návrh a použitie vlastného multitriedneho datasetu študentského výkonu,
- výpočet a interpretáciu metrík a charakteristík pravidiel,
- uloženie výsledkov vo forme pravidiel, tabuliek a doplnkových grafov,
- zachovanie dobrej interpretovateľnosti výsledného modelu.

Možné budúce rozšírenia sú:

- doplnenie signifikačného testu pre kandidátne pravidlá,
- spracovanie spojitých atribútov po discretizácii,
- vytvorenie samostatného skriptu pre dávkové porovnávanie viacerých konfigurácií,
- rozšírenie analýzy o plnohodnotné vyhodnotenie noisy datasetu.

Z celkového pohľadu možno konštatovať, že cieľ práce bol splnený. Vytvorené riešenie je funkčné, interpretovateľné a poskytuje dobrý základ pre ďalšie experimentovanie aj obhajobu zadania.